



Estructuras de Datos y Algoritmos Avanzados

Proyecto 2: Conteo de patrones

Profesor: José Fuentes Sepúlveda

Ayudante: Luciano Argomedo Solís

Objetivos

Los objetivos de este proyecto son:

- Mejorar la programación, compilación y ejecución de programas escritos en lenguaje *C++* u otros.
- Estudiar e implementar algoritmos y estructuras de datos para la búsqueda de patrones en texto.
- Analizar experimental y teóricamente el desempeño de estructuras ortodoxas y compactas.

1. Descripción del problema

La búsqueda de patrones en texto corresponde a uno de los problemas fundamentales en Ciencias de la Computación y vamos su aplicación cotidianamente. Por ejemplo, cada vez que presionamos la combinación de teclas `control + F` o `control + S`, a nivel de implementación se está utilizando una estructura de datos especializada para búsqueda en texto.

En este proyecto se implementarán tres soluciones para soportar búsqueda de patrones:

1. Búsqueda basada en arreglo de sufijos: Utilizando como base el arreglo de sufijos de un texto usando búsqueda binaria.
2. Búsqueda basada en arreglo de sufijos y el arreglo LCP: usando el SA y el LCP de manera conjunta ejecutando búsqueda binaria y acelerando las comparaciones mediante el LCP.
3. FM-index: Implementación simple del auto-índice FM-index, usando la Burrows-Wheeler Transform, los arreglos *Occ* y *C*, y la función LF-mapping.

2. Objetivos específicos

La entrega del proyecto, que consiste de un informe y el código fuente, debe satisfacer los siguientes objetivos:

- Cada estructura de datos y algoritmo deben proveer de la funcionalidad *count*(*T*, *p*), la cual retorna la cantidad de veces que el patrón *p* aparece en el texto *T*
- Describir las características principales (e.g. complejidades temporales y espaciales) de las estructuras de datos implementadas.
- Describir las decisiones de implementación más importantes.
- Plantear varias hipótesis sobre el rendimiento de las soluciones a comparar en escenarios específicos. Por ejemplo, “La solución *X* es más rápida buscando patrones que la solución *Y* cuando los datos cumplen cierta característica *C*” o “la solución *X* usa menos espacio que la solución *Y*”. Se deben plantear (por lo menos) tantas hipótesis como integrantes tenga el equipo.
- Diseñar un experimento que permita verificar cada hipótesis. Y como mínimo se debe mostrar el espacio usado de cada solución, el tiempo de construcción y el tiempo de conteo.
- Ejecutar los experimentos y discutir los resultados obtenidos.
- Mostrar los resultados mediante tablas y/o gráficos. En el caso de gráficos, mostrar uno por dataset con las 3 soluciones. En el caso que no se pueda distinguir el rendimiento con el gráfico en la escala que muestra todas las soluciones, hacer zoom para mostrar las soluciones con rendimiento similar.
- Se recomienda construir un gráfico donde el eje X sea el tiempo de construcción o de conteo y el eje Y el espacio usado por la estructura. Estos permiten comparar directamente las soluciones propuestas y determinar las mejores. Pueden usar un color por dataset y así reportar todos los resultados agrupados en un solo gráfico.

3. Condiciones

- El proyecto se realizará en grupos de **2 o 3** estudiantes. El informe debe reflejar claramente los autores del proyecto.
- Las estructuras de datos pueden ser obtenidas de una fuente externa, la cual debe ser referenciada en el informe. Además, el funcionamiento de las implementaciones obtenidas externamente deben estar detalladamente comentadas.

- Todas las implementaciones deben realizarse en el mismo lenguaje de programación y utilizar los mismos tipos de optimizaciones.
- En el informe se debe describir el entorno de *hardware* y *software* en que se ejecutan los experimentos. Además, debe quedar clara la manera en que se generan u obtienen tanto los datos de entrada como los resultados reportados. Una persona externa con la información descrita en el informe y el código fuente, debiera ser capaz de replicar los experimentos y obtener las mismas conclusiones.
- Los datasets mínimos a usar son los disponibles en el servidor chome en /home/dataset. Se deben usar al menos los siguientes textos: sources (202MB), dna (386MB), proteins (1.2GB), y el genoma del primer homo sapiens, GCF_000001405.40_GRCh38.p14_genomic.fna (3,2 GB).
- Con el objetivo de reducir ruido en los resultados, las mediciones realizadas deben contemplar al menos 30 repeticiones, de las cuales se reportará la media y varianza.

4. Evaluación

1. Un informe que:
 - a) Incluya portada, descripción de la tarea, descripción de las soluciones propuestas, detalles de implementación, análisis teórico y análisis experimental, considerando las condiciones previamente estipuladas.
 - b) Sea claro y esté bien escrito. Un informe difícil de entender será mal evaluado, aunque todo esté bien implementado. Quien revise el documento debe poder entender su solución solo mirando el informe.
 - c) Esté en formato pdf.
2. Un archivo comprimido con todo el código fuente implementado para solucionar la tarea. El informe debe hacer referencia al código y explicar en qué consiste.